

Politechnika Warszawska

W Y D Z I A Ł E L E K T R Y C Z N Y



Instytut Elektrotechniki Teoretycznej i Systemów Informacyjno-Pomiarowych

Praca dyplomowa magisterska

na kierunku Informatyka Stosowana
w specjalności Inżynieria Oprogramowania

Analiza metod mitygacji podatności dużych modeli językowych

Filip Sosnowski

numer albumu 319105

promotor

dr inż. Robert Szmurło

WARSZAWA 2026

Analiza metod mitygacji podatności dużych modeli językowych

Streszczenie

Słowa kluczowe:

Analysis of methods for mitigating vulnerabilities in Large Language Models

Abstract

Keywords:

Spis treści

1	Wstęp	9
1.1	Motywacja	9
1.2	Cel	9
1.3	Zawartość pracy	9
2	Metody ataku na duże modele językowe	11
3	Metody obrony przed atakami na duże modele językowe	13
3.1	Metody tekstowe	13
3.2	Zewnętrzne modele moderacyjne	13
3.3	Metody wewnętrzne	13
4	Projekt i implementacja środowiska badawczego	15
4.1	Architektura systemu testowego	15
4.2	Modele językowe	15
4.3	Zbiory danych	15
4.4	Implementacja wybranych metod obrony	15
4.5	Metryki	15
5	Analiza wyników badań	17
6	Podsumowanie	19
6.1	Podsumowanie	19
6.2	Możliwości dalszych badań	19
	Bibliografia	21
	Wykaz skrótów	21
	Spis rysunków	23

Rozdział 1

Wstęp

1.1 Motywacja

Moją motywacją do podjęcia tego tematu jest przede wszystkim

1.2 Cel

Głównym celem pracy jest

1.3 Zawartość pracy

Praca składa się z x rozdziałów. We wstępie omówiono motywację do podjęcia tematu, określono cele do zrealizowania oraz opisano strukturę pracy. Następny rozdział zawiera W rozdziale trzecim omówiono W podrozdziałach czwartej części ...

Rozdział 2

Metody ataku na duże modele językowe

Rozdział 3

Metody obrony przed atakami na duże modele językowe

3.1 Metody tekstowe

3.2 Zewnętrzne modele moderacyjne

3.3 Metody wewnętrzne

Rozdział 4

Projekt i implementacja środowiska badawczego

4.1 Architektura systemu testowego

4.2 Modele językowe

4.3 Zbiory danych

4.4 Implementacja wybranych metod obrony

4.5 Metryki

Rozdział 5

Analiza wyników badań

Rozdział 6

Podsumowanie

6.1 Podsumowanie

6.2 Możliwości dalszych badań

Wykaz skrótów

Spis rysunków